

面向稀疏课程推荐的可靠性自适应融合方法 智慧教育场景下的多源证据选择

徐子锐^{1†}

(1. 南京师范大学计算机与电子信息学院/人工智能学院, 江苏南京)

摘要: 智慧教育课程推荐面临用户交互稀疏、课程规模有限与知识图谱信息异构并存的挑战。针对这一场景, 本文系统比较了流行度、邻域协同过滤、线性重构、随机游走、神经协同过滤与知识图谱课程画像等多类排序证据, 并提出带语义可靠性门控的自适应融合方法 RAKF-M-G (Reliability-Adaptive Knowledge-aware Fusion with Gating and Masking)。实验结果显示, 在给定课程集合仅 698 门且用户历史极短的条件下, EASE 和 RP3 等非神经方法比 MF-BPR、LightGCN 更稳定; 知识图谱画像单独排序能力有限, 但可作为候选语义证据交由训练内验证门控筛选。RAKF-M-G 根据用户历史长度进行分组线性校准, 并用验证用户决定是否引入 KG profile。严格的全课程排序评测表明, RAKF-M-G 取得 0.5871 的 HR@10、0.6995 的 HR@20、0.3747 的 NDCG@10 和 0.4053 的 NDCG@20。消融实验与多随机种子验证进一步表明, RP3 和 EASE 分别构成短历史用户与多历史用户的重要排序证据, 基于历史长度的证据可靠性建模是性能提升的主要来源。

关键词: 课程推荐; 知识图谱; 隐式反馈; 可靠性自适应融合; 智慧教育

中图分类号: TP391

文献标识码: A

Reliability-Adaptive Fusion for Sparse Course Recommendation Evidence Selection in Smart Education Environments

Zirui Xu^{1†}

(1. School of Computer and Electronic Information / School of Artificial Intelligence, Nanjing Normal University,
Nanjing, Jiangsu, China)

Abstract: Sparse course recommendation in smart education is constrained by short user histories, a compact course catalog, and heterogeneous knowledge-graph signals. This paper proposes RAKF-M-G, Reliability-Adaptive Knowledge-aware Fusion with Gating and Masking, to calibrate multiple ranking evidences according to user history length. The study compares popularity ranking, ItemKNN, EASE, RP3, MF-BPR, LightGCN, and a course-side knowledge-graph profile under full-catalog ranking. Results show that EASE and RP3 are more stable than neural collaborative filtering on this sparse dataset. The knowledge-graph profile is weak as a standalone ranker, so it is treated as a candidate semantic signal and filtered by validation gating. RAKF-M-G selects fusion and gating coefficients on users held out from the training set. With training positives masked, it reaches 0.5871 HR@10, 0.6995 HR@20, 0.3747 NDCG@10, and 0.4053 NDCG@20 on the final test split. Ablation and multi-seed validation results indicate that history-length-aware evidence calibration is the main source of improvement.

Key words: course recommendation; knowledge graph; implicit feedback; adaptive fusion; smart education

1 引言

在线教育平台往往同时记录用户选课行为和课程侧知识结构。前者反映真实学习偏好, 但在本文所研究的数据场景中, 大量测试用户只有一到两个历史课程; 后者包含课程概念、教师、学校、先修关系等语义信息,

能够提供课程内容侧约束。稀疏交互与课程知识之间的稳定融合, 是该类课程推荐问题的核心。

训练集包含 614476 条用户课程交互, 测试集包含 68276 条交互; 训练用户数为 198135, 测试用户数为 55902, 其中 46409 个测试用户只有一个测试正例。课程总数仅 698, 适合采用全课程排序评测。由此可见, 该场景的关键难点集中在排序精度、冷启动稳健性和特征可靠性的共同约束上。

基线实验表明, Popularity 只能提供较弱的全局先

收稿日期: 2026-06-05; 定稿日期: 2026-06-05

基金项目: 无

[†] 通信作者: 徐子锐, E-mail: 1516924835@qq.com

验; EASE 和 RP3 明显优于 MF-BPR、LightGCN 等神经协同过滤模型, 并且二者适用的用户类型存在差异: 短历史用户更依赖 RP3 对单个锚点课程的路径传播, 多历史用户更受益于 EASE 的全局共选结构。上述结果说明, 统一的全局融合系数难以充分适配不同用户组的证据可靠性。因此, 本文将课程推荐建模为不同历史长度下的多源排序证据选择问题, 并据此设计 RAKF-M-G。

2 相关工作

2.1 隐式反馈推荐

隐式反馈推荐通常只观察到点击、观看或选课等正向行为, 而未观察项不能简单视为负样本。BPR 通过成对排序目标优化用户对正例和未观察项的偏好顺序 [1], 是矩阵分解推荐的重要基线。EASE 将用户项目矩阵重构为线性自编码器, 利用闭式解学习项目之间的全局相关性, 在稀疏隐式反馈上常具有较强表现 [3]。

2.2 图传播与课程知识

图推荐模型将用户、物品或知识实体视为图节点。LightGCN 去除常规图神经网络中的特征变换和非线性激活, 保留邻域传播以提高协同过滤效率 [4]。知识图谱推荐则通过实体关系为物品提供语义补充, KGAT 等方法展示了知识关系在推荐中的价值 [5]。在本文数据中, 课程侧知识图谱较完整, 用户侧交互极稀疏, 知识图谱更适合作为课程语义画像和校准信号融入协同过滤。

3 数据集与任务定义

3.1 数据概况

表 1 给出了核心统计。训练集与测试集之间没有重复的用户课程对, 所有测试课程均在训练课程集合中出现, 因此评测重点是用户偏好排序, 而非新课程冷启动。

知识图谱关系主要来自课程概念、视频概念、课程视频、教师课程、学校课程、先修依赖、父子概念和概念领域等边。规模较大的关系包括 video-concept 的 319948 条边、course-concept 的 167751 条边、parent-son 的 114611 条边和 concept-field 的 114563 条边。这些关系为课程侧语义画像提供了较充分的特征来源。

表 1 数据集统计

统计项	数值
训练交互数	614476
测试交互数	68276
用户总数	199199
课程总数	698
训练用户数	198135
测试用户数	55902
测试中新用户数	1064
测试单正例用户数	46409
训练矩阵密度	0.004443
训练测试重复交互	0

3.2 任务定义与评测口径

设训练交互矩阵为 $\mathbf{R} \in \{0, 1\}^{|\mathcal{U}| \times |\mathcal{I}|}$, 测试用户集合为 $\mathcal{U}_{test}$, 用户 u 的测试正例集合为 $\mathcal{T}_u$ 。对每个测试用户, 模型需要在全部 698 门课程上给出排序, 并遮蔽训练集中已学课程。全课程排序比采样负例更严格, 也更接近真实推荐列表生成。

采用 HR@K 和 NDCG@K 作为主指标:

$$\text{HR@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \mathbf{1}[\text{TopK}(u) \cap \mathcal{T}_u \neq \emptyset], \quad (1)$$

$$\text{NDCG@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \frac{\sum_{j=1}^K \frac{\text{rel}_{u,j}}{\log_2(j+1)}}{\text{IDCG}_{u,K}}. \quad (2)$$

其中 $\text{rel}_{u,j}$ 表示第 j 个推荐课程是否为测试正例。

4 方法

4.1 协同过滤证据

EASE 学习课程之间的线性重构权重:

$$\min_{\mathbf{B}} \|\mathbf{R} - \mathbf{R}\mathbf{B}\|_F^2 + \lambda \|\mathbf{B}\|_F^2, \quad \text{diag}(\mathbf{B}) = 0. \quad (3)$$

令 $\mathbf{P} = (\mathbf{R}^\top \mathbf{R} + \lambda \mathbf{I})^{-1}$, 则 $B_{ij} = -P_{ij}/P_{jj}$ 。EASE 适合课程数较小、交互矩阵稀疏但全局共选结构稳定的场景。

ItemKNN 使用课程向量间的余弦相似度, 并保留每门课程的 top-k 邻居。RP3 则在用户课程二部图上进行三步路径传播, 使用 α 调整路径强度, 使用 β 抑制过热课程。二者分别提供局部邻域证据和图传播证据。

4.2 知识图谱课程画像

对课程 i , 从 course-concept、concept-field、parent-son、teacher-course、school-course 和 prerequisite-

dependency 等课程侧关系中提取课程特征, 并进行文档频率过滤和归一化。为避免由未来行为泄漏测试课程, 本文不使用 user-course、user-video 和 user-video-act 等用户侧附加关系。用户语义画像由其历史课程特征平均得到, 用户对候选课程的知识图谱分数记为:

$$s_{ui}^{kg} = \text{sim}(\mathbf{p}_u, \mathbf{x}_i), \quad (4)$$

其中 $\mathbf{x}_i$ 为课程特征向量, $\mathbf{p}_u$ 为用户历史课程画像。知识图谱画像主要提供协同证据之外的语义补充。

4.3 可靠性自适应分组融合

不同用户历史长度对应不同证据可靠性。RAKF-M-G 将测试用户按训练历史长度划分为五组: 0、1、2、3-4、5 个及以上。对每个组件分数先做行内标准化, 再按分组线性融合系数求和:

$$s_{ui} = \sum_{m \in \mathcal{M}} w_{g(u), m} \cdot \text{Norm}(s_{ui}^m), \quad (5)$$




图 1 RAKF-M-G 的分组线性融合系数。A 为不同历史长度用户的证据系数, B 为各用户组的 HR@20 和 NDCG@20。

表 2 RAKF-M-G 分组效果

用户组	用户数	HR@20	NDCG@20
0 次历史	1064	0.6165	0.2508
1 次历史	19893	0.6901	0.4296
2 次历史	10716	0.6990	0.4141
3-4 次历史	11503	0.7069	0.4063
5 次及以上	12726	0.7151	0.3719

5 实验设置

实验包含非神经、图传播和神经协同过滤三类对照方法。Popularity 使用训练课程流行度排序; KG profile 只使用课程侧知识图谱画像; MF-BPR 使用矩阵分解和 BPR 损失; LightGCN 使用用户课程二部图传播; ItemKNN、EASE 和 RP3 作为强非神经基线。RKF-M

其中 $\mathcal{M}$ 包含 EASE、ItemKNN、RP3、Popularity 和 KG profile, $g(u)$ 为用户历史长度分组。系数 w 表示训练集内部 leave-one-out 验证得到的线性校准系数, 并非非负归一化的注意力权重, 因此可能出现小幅负值。KG profile 作为候选语义证据进入搜索, 其实际贡献由分组门控项 γ_g 控制:

$$w_{g, kg} = \gamma_g \cdot \tilde{w}_{g, kg}, \quad \gamma_g \in \{0, 1\}. \quad (6)$$

当训练内验证显示某用户组的 KG 排序证据不稳定时, 门控项会抑制该候选证据, 避免弱语义信号损害最终排序; 当 KG 对验证排序有帮助时, 则保留其语义校准作用。对于 0 次历史用户, 训练内验证集无法直接构造同类验证用户, 最终采用验证集中最优固定融合系数, 并回退到课程流行度等全局先验。

表示训练内验证选择的固定融合模型, RAKF-M-G 表示在其基础上加入历史长度分组和 KG 可靠性门控的自适应融合模型。神经模型在远程 GPU 服务器上训练, 环境为 NVIDIA GeForce RTX 4090D 与 PyTorch 2.5.1+cu121; 其余全排序实验在统一评测代码中完成。

所有方法均在相同训练集上建模, 并在相同测试用户上评估。由于课程总数只有 698, 采样负例评测容易使指标偏高, 且不符合真实推荐列表生成方式, 因此实验采用全课程排序; 若用户在训练集中已经学习某课程, 则该课程在推荐列表中被遮蔽。为避免直接使用测试集调参, 融合系数的选择在训练集内部进行: 从有至少两条训练交互的用户中留出一个课程作为验证正例, 固定随机种子抽样验证用户搜索固定融合和分组融合系数, 最终测试集仅用于性能评估。除主实验外, 本文还用三个随机种子重复训练内验证抽样, 用于检

表 4 主要模型全排序结果

模型	HR@10	HR@20	NDCG@10	NDCG@20
Popularity	0.3410	0.4505	0.1792	0.2071
KG profile	0.2971	0.3847	0.1771	0.1987
MF-BPR	0.5164	0.6257	0.3254	0.3541
LightGCN	0.5141	0.6135	0.3260	0.3525
ItemKNN	0.5578	0.6716	0.3514	0.3821
EASE	0.5791	0.6888	0.3676	0.3976
RP3	0.5813	0.6945	0.3686	0.3992
RKF-M	0.5836	0.6952	0.3723	0.4027
RAKF-M-G	0.5871	0.6995	0.3747	0.4053




图 5 主结果总览。虚线表示 EASE 基线，最终版本在 HR@20 与 NDCG@20 上都高于几组强基线。

选，而不是无条件注入最终排序。

表 6 进一步把这种观察拆到用户组上。0 次历史用户没有个人历史，几个模型都会回退到全局先验，因此 NDCG@20 完全一致；1 次历史用户上 RP3 和 RAKF-M-G 最好，说明单个锚点课程更适合路径传播；5 次及以上用户上 RP3 明显低于 EASE、RKF-M 和 RAKF-M-G，说明历史较长时只围绕局部路径扩散反而会损失稳定兴趣。

表 7 对不同历史长度用户的典型误差模式进行归纳。短历史用户更依赖锚点传播，多历史用户更需要全局共选与课程语义共同约束。

6.4 验证稳定性检查

为检查分组融合是否只依赖某一次验证用户抽样，本文在训练集内部重复三次 leave-one-out 验证切分，并在每个随机种子下抽取 15000 个验证用户重新搜索候选融合系数。该检查不改变最终测试集汇报口径，只用于观察验证阶段的选择是否稳定。表 8 显示，RAKF-M 在三个随机种子下均高于固定融合 RKF-M，NDCG@20 平均提升 0.0019，HR@20 平均提升 0.0044。增益幅度不大，但方向一致，说明历史长度分组不是由单次抽样偶然造成的；RAKF-M-G 在此基础上进一步加入 KG 可靠性门控。

表 8 训练内验证随机种子稳定性




图 6 多源证据组合路径。A 展示从流行度、协同证据到自适应融合的 NDCG@20 变化，B 和 C 分别展示相对 EASE 的 NDCG@20 与 HR@20 增益。

表 5 正式模块消融结果

模型变体	HR@10	HR@20	NDCG@10	NDCG@20
RAKF-M-G full	0.5871	0.6995	0.3747	0.4053
non-gated KG mix	0.5870	0.6986	0.3745	0.4049
w/o RP3	0.5784	0.6886	0.3696	0.3995
w/o EASE	0.5832	0.6959	0.3702	0.4009
w/o adaptive grouping	0.5836	0.6952	0.3723	0.4027
KG profile only	0.2971	0.3847	0.1771	0.1987




图 7 正式消融实验。A 为各变体 NDCG@20，B 和 C 分别为相对完整 RAKF-M-G 的 NDCG@20 与 HR@20 变化。

随机种子	RKF-M	RAKF-M	ΔNDCG@20
20260604	0.3872	0.3890	+0.0017
20260605	0.3920	0.3936	+0.0016
20260606	0.3905	0.3928	+0.0023
平均	0.3899	0.3918	+0.0019

表 6 不同历史长度用户上的 NDCG@20 对比

用户组	用户数	EASE	RP3	RKF-M	RAKF-M-G
0 次历史	1064	0.2508	0.2508	0.2508	0.2508
1 次历史	19893	0.4168	0.4296	0.4253	0.4296
2 次历史	10716	0.4097	0.4122	0.4140	0.4141
3-4 次历史	11503	0.4021	0.4012	0.4075	0.4063
5 次及以上	12726	0.3656	0.3514	0.3661	0.3719

表 7 不同历史长度下的典型误差观察

用户类型	历史特点	单一证据的主要问题	RAKF-M-G 的处理
1 次历史	只有一个锚点课程	EASE 容易受热门共现影响	主要采用 RP3 路径传播
5 次及以上	兴趣方向较稳定但更分散	RP3 可能过度围绕局部课程扩散	提高 EASE, 门控弱语义噪声

6.5 数据分布解释

图 8 显示了用户历史长度、课程流行度和知识图谱关系规模。用户历史分布明显偏左, 说明许多用户只有极少数历史课程。课程流行度也呈长尾分布, 热门课程会影响流行度和协同过滤得分。知识图谱关系较丰富, 适合作为课程内容侧补充, 但其用户个性化能力依赖历史课程画像。因此, RAKF-M-G 按历史长度划分系数并对 KG 信号加门控, 是与数据结构相匹配的设置。

计。

图 8D 中还有一个需要解释的现象: HR@20 随着历史长度总体上升, 但 NDCG@20 从 1 次历史用户的 0.4296 下降到 5 次及以上用户的 0.3719。原因可能是多历史用户更容易在 Top20 内命中至少一个测试正例, 所以 HR 较高; 但这类用户兴趣更分散, 测试正例也可能来自多个学习方向, 因此把正例排到列表最前面的难度更大, NDCG 未必同步提升。




图 8 数据与知识图谱画像。A 为用户训练历史长度分布, B 为课程流行度分布, C 为主要知识图谱关系边数, D 为分组用户规模与分组指标, 其中蓝线为 HR@20, 橙线为 NDCG@20。

7 讨论

RAKF-M-G 的提升主要来自两个方面。第一, 不同协同证据捕捉的结构不同: EASE 对全局课程共选

关系敏感, RP3 对少量锚点课程的路径传播更敏感, ItemKNN 提供局部邻域补充。第二, 分组融合将这些证据分配到更合适的用户组, 并通过验证门控筛选 KG profile 这类候选语义证据。表 6 中 1 次历史和 5 次及以上用户的差异表明, 历史长度分组能够处理不同用户组下的证据可靠性差异。表 8 进一步说明, 这种差异并不是只在某一次验证抽样中出现。知识图谱画像在当前版本中更多承担课程语义补充、结果解释和候选校准作用; 正式消融显示, 无条件混入 KG profile 会轻微降低总体指标, 而门控机制可以保留语义建模过程并避免弱信号拖累排序。

本文方法也存在限制。第一, 实验没有继续堆叠 KGAT 等更复杂的知识图谱模型。这样处理并不是忽略知识图谱, 而是基于本数据中用户侧交互过稀疏、课程数较小的事实: 复杂模型如果缺少足够监督, 未必能稳定超过 EASE 和 RP3。第二, 训练内验证已经通过多个随机种子检查稳定性, 但仍不是完整的多折交叉验证。第三, 知识图谱画像主要使用课程侧关系, 没有使用可能造成泄漏风险的用户视频行为。后续研究可进一步考察更强的知识图谱推荐模型、多折验证、时间衰减、课程层级难度和学习路径约束。

8 结论

本文提出了一种面向稀疏课程推荐的可靠性自适应融合方法 RAKF-M-G。该方法整合线性重构、邻域相似、随机游走、流行度和知识图谱课程画像等多源排序证据, 并基于用户历史长度对证据可靠性进行分组加权和 KG 门控。在全课程排序、遮蔽训练正例的评测设置下, 训练内验证选择的 RAKF-M-G 达到 0.5871 HR@10、0.6995 HR@20、0.3747 NDCG@10 和 0.4053 NDCG@20。消融实验和多随机种子验证检查揭示了两个关键结论: 第一, RP3 和 EASE 分别构成短历史用户和多历史用户的重要排序证据; 第二, 基于历史长度的自适应融合是性能提升的主要来源。知识图谱画像有助于课程语义解释和内容侧校准, 但需要通过验证门控避免不稳定信号损害总体排序。这些发现表明, 在稀疏课程推荐场景下, 对不同用户群体进行证据可靠性建模, 比采用全局统一的复杂模型更有效。

参考文献

[1] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking from implicit feedback[C]. Proceedings of UAI, 2009.

- [2] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms[C]. Proceedings of WWW, 2001: 285–295.
- [3] Steck H. Embarrassingly shallow autoencoders for sparse data[C]. The World Wide Web Conference, 2019: 3251–3257.
- [4] He X, Deng K, Wang X, et al. LightGCN: Simplifying and powering graph convolution network for recommendation[C]. Proceedings of SIGIR, 2020: 639–648.
- [5] Wang X, He X, Cao Y, et al. KGAT: Knowledge graph attention network for recommendation[C]. Proceedings of KDD, 2019: 950–958.
- [6] Cremonesi P, Koren Y, Turrin R. Performance of recommender algorithms on top-N recommendation tasks[C]. Proceedings of RecSys, 2010: 39–46.

作者简介:



徐子锐, 学号 19230444, 本科生, 主要研究领域为推荐系统、知识图谱与智慧教育数据分析。

E-mail: 1516924835@qq.com